


研究报告 / 技术体系与实验证据

面向 GPU 内核优化的 智能体与编译器协同演进

Agent-Compiler Co-Evolution for GPU Kernel Optimization

秦海岩 Haiyan Qin
北京航空航天大学

2026 年 9 月 24 日更新
阅读快照 / 源码 677eb444



报告边界 正文所读源码固定为 677eb444fec593294c470dcc5793262ae769fce2。第 8 节另列 2026 年 9 月 24 日的 B300-M4 后继诊断，明确标出较新的编译器提交和验收边界。历史设备实验仍绑定各自的源码、精确目标、Workload、oracle 和计时协议；原有仓库引用指向所读的固定提交。

摘要

同一个算子可以有許多 GPU 实现：它们遵循相同的数学公式，却采用不同的分块、线程分工、存储和同步方式。智能体生成内核后，仅凭编译错误或一个延迟值，往往难以判断下一步该修改候选程序，还是该补足编译器的表达与检查能力。open-cake-ir 用带类型的执行计划记录这些硬件选择，在生成代码前给出可定位的诊断；任务语义、正确性检查、设备计时和运行证据则由各自的模块负责。一次优化运行使用固定的编译器，任务反复暴露出的编译器缺口在后继版本中修复，再回到新任务验证。

当前源码声明五家厂商的八个精确目标，179 项语料检查符合预期。NVIDIA、Apple、Hygon 和 MetaX 已有范围各异的结果；AMD 的设备计时仍在校准。同形状的 TinyGEMM2 对照通过了严格数值检查。历史实现曾慢 13–37 倍；后继 B300-M4 诊断已大幅缩小差距。最新固定形状的配对测量中， $B = 64$ 本地候选为 $19.904\ \mu\text{s}$ ，快于 CAKE 导出产物的 $21.440\ \mu\text{s}$ ； $B = 16$ 仍慢约 1%， $B = 1$ 的外部比较未通过波动门限。这些是尚未进入正式 Evaluation 的局部测量。已有证据说明系统能够承载这些任务和局部优化；经验材料能否帮助智能体在另一种硬件上更快找到好实现，还需要预先分组的实机实验。

关键词：GPU 内核；中间表示；静态验证；智能体；实验可复查性；跨硬件优化

ABSTRACT

open-cake-ir independently implements a CAKE-inspired system in which agents author typed, hardware-explicit schedules, receive localized compiler feedback, and validate candidates against external oracles and target-specific measurements.

A corpus-gated compiler successor is introduced between frozen optimization runs. The implementation declares eight exact targets across five vendors; device correctness and measurement coverage remain uneven. A same-shape TinyGEMM2 comparison passes strict numerical checks. Later B300-M4 diagnostics substantially narrowed the historical gap. On the fixed $B = 64$ shape, a committed candidate measured $19.904\ \mu\text{s}$ versus $21.440\ \mu\text{s}$ for the CAKE export, a 1.079-times paired lead. The $B = 16$ candidate remains about 1% slower; the $B = 1$ external comparison fails its variability gate. These successor measurements are not formal Evaluation results. Cross-hardware knowledge-transfer effects remain unmeasured. The primary software snapshot is commit 677eb444; each measurement retains its own source and assay boundary.

阅读约定

阅读结果时，请先看它经过哪一层检查。语料门说明编译器符合已审查的软件预期；设备正确性与计时结果还要说明目标型号、任务、运行版本和测量质量。比较两种智能体编写环境的效果，则需要预先分组的独立运行和同一套确认规则。本文把历史实验、当前仓库记录与 CAKE 论文报告的数字分别标明。

内容导览

1 问题、研究对象与论点	3	6.2 双时间尺度与 Finding 的负责位置 . . .	12
1.1 背景：公式、执行计划与智能体反馈	3	6.3 研究对照的单位和参考访问	13
1.2 CAKE 论文提供的研究起点	3	6.4 证据保存、回放与结论资格	13
1.3 本工作的定位与当前贡献	3	6.5 结论阶梯	13
2 设计原则与实现边界	4	7 实现覆盖与代表性设备案例	13
3 系统合同与职责边界	4	7.1 平台覆盖是分层事实	13
3.1 从任务到可审计结论	4	7.2 NVIDIA：任务族覆盖与外部比较 . .	15
3.2 编译器：检查程序，再生成目标源码	5	7.3 Apple、Hygon、AMD：不同结论等级	15
3.3 实验系统：固定一次优化的条件 . . .	5	7.4 MetaX：单内核、完整输出和实际 Run 分别验收	15
3.4 评测与证据：先判对，再解释速度 .	6	7.5 案例 A：C550 的局部 tiling 收益 . . .	16
3.5 两个时钟：候选搜索与编译器演进 .	6	7.6 案例 B：B300 的对齐条件与质量门 .	16
4 程序表示：任务、完整程序与执行计划	6	7.7 两个局部案例的结论范围	16
4.1 显式的计划，而非新的布局代数 . . .	6	7.8 历史 B200 案例的放置方式	16
4.2 受限 Python 前端与同一规范 IR . . .	6	8 与 CAKE 对照：相同的问题，不同的证据	16
4.3 从 Python Schedule 到 Triton：一次实 际生成	7	8.1 TinyGEMM2：相同任务上的性能差距	17
4.4 一个数值反例：FMA 与乘加	9	9 跨硬件复用：从一次改写到可检验的收益	19
4.5 完整 Program 的阶段与绑定	9	9.1 可复用的是机制，参数要在目标卡 重选	19
4.6 精确目标文档	10	9.2 E/P 四组实验	19
4.7 表示变更的验收义务	10	9.3 从 B300 到 Hygon：可执行与性能的 分界	20
5 编译器：从局部化检查到目标源码	10	10 限制、可复查性与结论	20
5.1 分层拒绝与反馈	10	10.1 解释结果时的四项限制	20
5.2 源码生成与下游工具链	11	10.2 下一步的可检验目标	21
5.3 Target 与生成路线如何保持分离 . . .	11	A 术语、源码入口与完整示例	22
5.4 从 Finding 到物理资源观察	11	B 结果来源与历史身份	23
5.5 Corpus Gate 的含义	12	C 复现边界与报告构建	23
6 实验方法与证据等级	12		
6.1 一次 Run 的四阶段	12		

1 问题、研究对象与论点

以按行计算的 Softmax 为例，公式确定了每行应得到什么结果，却没有规定一个 GPU 程序处理多少行、由哪些线程完成归约，也没有规定中间值放在哪里。智能体可以尝试多种安排；其中有的地址或同步关系不成立，有的虽然算对，却比原实现慢。要继续改进，智能体需要知道具体是哪项选择出了问题，而不只是收到“编译失败”或一个延迟数字。

本报告研究的是这样一套编写环境：智能体修改明确的执行计划，编译器在生成代码前检查可判断的关系，设备评测再回答结果是否正确、性能是否改善。当任务反复暴露出表达或分析缺口时，维护者改进编译器，并在后续任务中检验这项改动。贯穿全文的问题是：

核心问题 怎样在固定任务和可追溯的实验条件下，让智能体的 GPU 执行选择可以被检查、失败可以被定位，并将反复出现的问题转化为后续可用的编译能力？

CAKE 论文提出了编译器与智能体协同改进内核的研究路线 [1]。open-cake-ir 沿着这一问题独立实现了程序表示、编译检查和实验流程，并把不同硬件上的观察保留在各自的任务与测量范围内 [6]。

1.1 背景：公式、执行计划与智能体反馈

数学公式与设备程序之间隔着一层执行安排。以内核中的行归约为例，行块大小改变了每个程序实例承担的工作；线程分工影响归约时的通信；中间值的存放方式又影响寄存器与共享内存压力。编译器可以检查一部分地址、数据流和同步关系，物理资源分配与速度则要到编译产物和设备上观察。因此，一个候选的反馈需要指出检查到了哪一层，以及问题落在哪个操作或资源上。

这些观察还决定改动应当留在哪个位置。某种分块在当前形状上更快，可以先保留为任务候选；换到另一目标时，需要重新选参数并验证；若同类改写在不同任务中反复有效，才有理由提炼带适用条件的编译器变换。报告将依次展示这三层工作所依据的程序、诊断和设备记录。

1.2 CAKE 论文提供的研究起点

CAKE 让智能体编写一份带类型的硬件执行计划。计划写明资源、线程角色、数据访问和同步；屏障地址与流水线阶段位等机械细节由编译器推导。编译器先检查程序安全、硬件约束、数据一致性和调度语义，再把有希望的候选送去编译与设备评测。任务中反复出现的失败，可以推动后续增加原语、改进检查规则或校准性能估计。CAKE 的重点因此不只是生成更快的内核，也是让编译环境随着任务一起改进 [1]。

论文在 B200 上用固定形状的 Flash-KMeans 任务比较了两种编写环境：一组由智能体编写 Cake IR，另一组直接编写 CUDA/PTX；目标的低层实现都不向作者开放。两组各运行三次，共同使用 80M provider-token 截点。这个实验比较的是整套编写环境，包括表示、检查和反馈，并未单独测量 IR 语法的作用。论文中的 KDA 服务及其他性能数字也属于原研究的结果；本文讨论本仓库时，会另列其独立运行的证据。CAKE 论文覆盖的目标是 NVIDIA Ampere 至 Blackwell，非 NVIDIA 平台的实现和测量需要另建证据 [1, 6]。

1.3 本工作的定位与当前贡献

open-cake-ir 将 CAKE 提出的研究问题落到一套可独立检查的开源实现上。编译器单独接受完整程序及其内核计划，按精确目标给出诊断与生成源码；实验系统负责固定任务、作者材料和预算，评

测与证据模块保留设备结果及运行过程。这种分工让一次内核优化的结果有出处，也让编译器的后继改动能够回到触发它的任务接受验证。

仓库目前支持五家厂商的八个精确目标，并在若干目标上保留了正确性、计时或完整程序的有界案例。本文的贡献是把这些程序表示、检查机制和实验证据放在同一条可读的路径上，说明各目标已经走到哪一步，以及与 CAKE 公开产物重叠的任务还差在哪里。跨硬件经验是否能额外降低智能体的搜索成本，是这一基础之上的下一项实验问题。

2 设计原则与实现边界

CAKE 在附录 B.1 给出八项 IR 设计原则 [1]。本仓库沿用这些原则来约束新的执行计划语法、检查规则和后端能力。表 1 列出它们在实现中的具体落点。

表 1 P1–P8 对本仓库的实际约束。具体语法和目标准入仍以源码合同为准。

原则	本仓库的实现落点
P1 易于编写	Python 前端提供变量、表达式和角色作用域；网格细节由计划和编译器推导。
P2 性能透明	影响性能的分块、执行组、存储、访问和同步选择保留在 Schedule 中。
P3 规范形式	Python 与 JSON 进入同一套类型和操作模型。
P4 静态类型	类型、操作数与形状错误在构造和检查阶段定位。
P5 可分析	IR 显式保留 Verifier 与资源分析需要的数据和执行关系。
P6 语料门	新语义同时接受既有正例与反例的 Corpus Gate 检查。
P7 分析一致	数据模型改动同时更新对应的合法性与资源分析。
P8 硬件根据	目标指令、存储和同步承诺由 Target 与后端说明其适用范围。

硬件事实由精确目标文档声明。遇到未建模的资源上限，系统明确报告覆盖缺口；遇到目标不支持的指令，后端给出拒绝原因。这样，一份计划不会因为名称相近而悄悄降到另一架构。静态检查负责在已建模的范围内提前发现问题，真实输出与速度仍由设备评测确认。

编译器还要保持独立。它解释程序和目标，却不读取研究分组、作者工具或证据库。一次运行固定编译器与任务，运行中比较候选；编译器自身的修改在后继提交通过语料检查后，才用于下一轮任务 [2, 5]。

3 系统合同与职责边界

3.1 从任务到可审计结论

一次内核优化从任务合同（Workload Contract）开始。它规定输入、输出、数学定义和数值容差，给所有候选提供同一个判题标准。智能体提交的执行计划（Schedule）则写明这个内核怎样分工、读取、计算和同步；需要多个内核时，完整程序（Program）再说明阶段顺序及张量如何交接。

运行规格（RunSpecification）把这次尝试使用的源码、目标硬件、可见材料和预算固定下来。如果目的是比较两种编写条件，研究计划（StudyPlan）还要在运行前分配组别、终点和分析规则。表 2 列出这些事实各由谁负责；有了这样的分工，读者才能从一次候选追溯到它实际参加了哪项任务与评测 [2, 15]。

表 2 从任务到结论的负责位置。每一行给下一阶段提供事实或产物。

对象或模块	拥有的事实	对外给出的产物
Workload	数学、形状、输入分布、外部答案	不随候选改变的验收合同
Compiler	IR 类型、Target、合法性、后端准入与生成	Assessment、Finding、目标源码
Lab	材料、候选搜索、预算与 Run 控制	已提交候选和过程事件
Evaluation	外部正确性、目标计时质量和剖析	独立的检查、计时和 profiler 收据
Evidence	原始文件、事件、回放与审计	可由原始材料重建的报告
Study	处理分配、估计量和缺失策略	限定研究问题的分析结果

图1展示了典型运行路径。实验系统调用编译器检查候选，再把可运行产物交给评测；评测与证据记录一起返回下一轮。编译器也可以脱离实验系统单独使用，例如在没有 GPU 的机器上检查 FMA 示例。模块依赖与源码入口见 [架构章节](#)和[职责地图](#)。



图 1 一次运行中的候选路径。任务提供外部答案，实验系统管理候选，编译器生成源码，评测和证据模块把可核对的结果送回智能体；上方的研究计划只在需要分组比较时使用。

3.2 编译器：检查程序，再生成目标源码

编译器读入完整程序及其各阶段计划，在一个精确目标上检查类型、张量绑定、数据依赖和硬件约束。检查结果把两个问题分开回答：`Assessment.accepted` 说明计划是否符合通用语义规则；`lowering_eligible` 说明所选后端能否把它生成源码。比如，计划本身可以表达一种操作，某个后端却尚未实现对应指令，此时反馈会指出后端能力缺口。

通过检查的计划由后端确定性生成可阅读的源码。编译器中的显式改写也必须给出完整的新候选，或说明为何拒绝改写。这些判断只依赖程序、目标与编译器版本；实验组别和设备测量由后面的模块处理 [2, 3]。

3.3 实验系统：固定一次优化的条件

一次运行开始前，实验系统先核对任务、编译器、执行环境、基线和预算，再向编写内核候选的智能体提供获准查看的任务材料。搜索中，智能体提交候选，控制器记录剩余的编译与评测次数。搜索结束时，系统从已有候选中固定一个提名，用独立的新样本确认其正确性与性能；确认结果出现后，提名不再改换。

普通工程运行只需自己的运行规格。研究比较则由研究计划提前分配处理组，并让各组沿用同一执行与评测流程。旧实验使用的 CampaignLock 保留为输入适配层，历史数据仍按产生它的版本解释。这使智能体能看什么、能调用什么工具、何时停止，都在结果出现前确定。

3.4 评测与证据：先判对，再解释速度

评测模块先用任务合同生成输入，与外部参考逐项核对输出。候选算对之后，才按目标设备的计时与状态重置约定采集样本，并在需要时运行性能剖析。搜索读数、独立确认和剖析结果各有单独收据。若计时波动超过质量门，记录说明的是测量尚不足以判定快慢；候选的数值正确性仍按先前的检查结果保留。

证据模块保存候选文件、事件顺序、评测收据和终态。独立审计可以在不再调用智能体服务或 GPU 的情况下重建运行过程；研究分析只使用通过审计的结果。对多阶段程序，评测还要核对每次启动的顺序与最终输出，并按实际程序区间计时。单内核的计时收据只能回答那次内核调用的问题[5]。

3.5 两个时钟：候选搜索与编译器演进

候选和编译器沿两条时间线变化。在一次运行里，任务、目标、编译器及测量规则保持固定；智能体改变的是执行计划。检查与设备评测指出下一份候选该改哪里，也让不同候选的结果可以在同一条件下比较。

如果多次运行都遇到相同的表达或检查缺口，维护者才在运行之外修改编译器。新版本先经过语料测试与代码审查，再用于下一轮任务。这样，旧运行的结果仍对应旧编译器，新运行才能检验编译器改动有没有解决原来的问题[2, 5]。

4 程序表示：任务、完整程序与执行计划

4.1 显式的计划，而非新的布局代数

对每一行做 Softmax，任务规定的是结果：若 $m = \max_k x_k$ ，则 $y_j = \exp(x_j - m) / \sum_k \exp(x_k - m)$ 。执行计划要补上公式没有写出的事：每个程序实例处理几行，哪些执行组负责归约，中间结果放在哪里，以及按什么坐标写回。图 2 以仓库示例中的 64 行块展示这些选择。

Schedule 把操作、缓冲区、执行组、访问坐标、循环和同步关系存成带类型的结构。编译器因此可以检查：读取和写回是否指向同一行，两组是否争写同一输出，目标是否接纳所需指令。它要求作者写明具体的存储与访问承诺，却没有另设一套通用布局代数；Triton 等下游工具链继续负责物理布局、寄存器分配和最终指令选择[3, 2]。

当计算需要多个内核时，Program 将各阶段接成一个完整程序，声明它们共享的输入输出、执行顺序和张量绑定。此时验收对象是程序的最终输出与完整调用区间，而非某一个阶段的单独速度。

4.2 受限 Python 前端与同一规范 IR

示例把 Python 前端导入为 cake，用它声明 @cake.schedule 和张量参数；函数的第一个形参 lm 是 Schedule 上下文的语法名字：前端识别它的方法调用，不会执行一个运行时的 lm 对象。仓库没有为 lm 规定缩写含义；把形参及函数体中的引用一起改名为 ctx，仍会得到同一份规范 Schedule。lm.program 选择行块，lm.role 指定执行组，角色作用域内的调用描述读取、归约、广播和写回。前端解析受支持的 Python 语法树，并为诊断保留源码位置；它不会运行源文件的导入语句或函数体[3]。下面摘录的是当前 Softmax 示例中的实际操作：



图 2 同一 Softmax 公式对应的一份具体执行计划：每个实例处理 64 行，由四个执行组完成读取、归约和写回。图改绘自[仓库原图](#)，展示的是候选结构，而非计时结果。

```

compute = lm.role(execution_groups=[0, 1, 2, 3])
row_block = lm.program(x, axis=0, dimension=1, tile=64)
batch = lm.program(x, axis=1, dimension=0, tile=1)
with compute:
    x_tile = lm.load(x[batch, row_block, :], reuse="reused", id="load_x")
    rowmax = lm.reduce(x_tile, op="max", axis=1, scope="cta", id="row_max")
    shifted = lm.sub(x_tile, lm.broadcast(rowmax, axis=0), id="shift")
    weights = lm.exp(shifted, id="exponentiate")
    rowsum = lm.reduce(weights, op="sum", axis=1, scope="cta", id="row_sum")
    y_tile = lm.div(weights, lm.broadcast(rowsum, axis=0), id="normalize")
    lm.store(y[batch, row_block, :], y_tile, id="store_y")
  
```

示例输入输出都是 [8, 512, 128] 的 FP32 张量，目标是 sm_100a，生成路线为 Triton。tile=64 使每个实例负责 64 行；四个执行组完成同一份行块上的工作。行最大值和行和先广播回列维度，再参与逐元素计算；最后仍按原来的行块坐标写回。换一种分块或分工，编译器会重新检查计划，设备评测再判断它是否算对、是否更快。

作者在 Python 装饰器中无需手填任务内容的哈希。独立调用编译器时，可以直接检查计划；进入实验系统后，系统先核对目标、生成路线和公开张量接口，再绑定这次运行冻结的任务。这样，任务身份由实验输入决定，作者只编辑实现方案。具体准入规则见[前端合同](#)。

4.3 从 Python Schedule 到 Triton：一次实际生成

对上面的 Softmax，固定源码 677eb444 的 Compiler 先把 Python 语法树转换为带类型的 Schedule，再检查形状、访问、操作依赖和目标约束。本例的结构检查通过，Triton 生成路线可用；报告另给出 REGISTER_PRESSURE 与 RESIDENCY_BOUND 两条提示。随后执行 lower，得到下面的 Triton 内核体节选；两处较长的地址表达式只按页宽重新折行。代码中的 CAKE_OP 注释保留了原计划的操作 ID，便于从生成代码找回 load_x、row_max 等编写位置。

对照速览：lm.program 的 64 行块变成程序 ID 与行偏移；lm.load 的访问变成地址、边界掩码和 tl.load；行归约与广播变成 tl.max/tl.sum 和 [:, None]。编译器还把四个执行组写入启动参数 num_warps=4。

```

row_block = tl.program_id(0)
batch = tl.program_id(1)
row_block_offsets = row_block * BLOCK_ROW_BLOCK + tl.arange(0, BLOCK_ROW_BLOCK)
x_d2_offsets = tl.arange(0, D_X_2)
y_d2_offsets = tl.arange(0, D_Y_2)

# CAKE_OP:load_x
load_x_ptrs = (
    x + batch * N_ROW_BLOCK * D_X_2
    + row_block_offsets[:, None] * D_X_2
    + x_d2_offsets[None, :]
)
x_tile = tl.load(
    load_x_ptrs,
    mask=row_block_offsets[:, None] < N_ROW_BLOCK,
    other=0.0,
    eviction_policy="evict_last",
)
# CAKE_OP:row_max
rowmax = tl.max(x_tile.to(tl.float32), axis=1)
# CAKE_OP:shift
shifted = x_tile - rowmax[:, None]

# CAKE_OP:exponentiate
weights = tl.exp(shifted)

# CAKE_OP:row_sum
rowsum = tl.sum(weights.to(tl.float32), axis=1)
# CAKE_OP:normalize
y_tile = weights / rowsum[:, None]

# CAKE_OP:store_y
tl.store(
    y + batch * D_Y_1 * D_Y_2
    + row_block_offsets[:, None] * D_Y_2
    + y_d2_offsets[None, :],
    y_tile,
    mask=row_block_offsets[:, None] < D_Y_1,
)

```

摘录省略了函数签名和宿主启动包装。完整文件还核对输入的形状、dtype、设备和连续性，随后将 $512/64 = 8$ 个行块与 8 个 batch 组成 (8, 8, 1) 网格，传入 BLOCK_ROW_BLOCK=64、num_warps=4 和 maxnreg=96。其中的 tl 是实际导入的 triton.language；前面的 lm 只是 Cake 前端识别的形参名。

读者可在固定源码的根目录运行下列命令，查看包含函数签名、输入检查和启动包装的完整生成文件。这个步骤只生成 Python/Triton 源码，设备编译、正确性和速度另由评测确认。

```

PYTHONPATH=src python3 -m open_cake_ir.cli compiler assess \
    examples/python/softmax.py --format text
PYTHONPATH=src python3 -m open_cake_ir.cli compiler lower \
    examples/python/softmax.py --output /tmp/cake-softmax-generated.py --format text

```

4.4 一个数值反例：FMA 与乘加

FMA 说明为什么公式相同，还要写清计算语义。 $a \times b + c$ 可以先乘后加、舍入两次；融合乘加只在最终结果处舍入一次，某些输入下两者会得到不同的 FP32 值。当前 FMA 示例处理 $[8, 128]$ 输入，显式请求 `ptx.fma.rn.f32`。图3把任务公式和这份计划的分工放在一起：公式规定应算什么，计划规定八行怎样分配、数据怎样读取和写回[3]。




图 3 FMA 示例的任务与计划。图按仓库原图重绘；高亮行代表一个程序实例要处理的数据，逻辑寄存器 tile 的长度并非每线程物理寄存器数。

4.5 完整 Program 的阶段与绑定

QSA Program v4 是一份可检查的多阶段实例。其任务在 $B = 1, T = 32768$ 时读入 q, k, v 、索引查询与索引键，最终写出 BF16 的 output，形状为 $[1, 32768, 32, 128]$ 。Program 中的五个阶段各有一份独立 Schedule；下表直接按合同中的张量绑定与阶段顺序展开，而不是只用“池化、选择、注意力”概括整个程序。

表 3 QSA Program v4 的实际五阶段数据流。形状来自固定 $B = 1, T = 32768$ 的任务与 Program 合同；本表描述程序结构，不代表第7节历史候选的计时。

阶段	读取的张量	写出的张量及作用
pool	index_k	pooled: FP32 [8192, 128]，每 4 个索引键池化一次
layernorm	pooled, k_norm_weight	normalized_keys: FP32 [8192, 128]
score_topk	index_q, normalized_keys	block_indices: INT32 [32768, 512]，每个查询选 512 个块
expand	block_indices	token_indices: INT32 [32768, 2048]，展开为 token 位置
attention	$q, k, v, \text{token_indices}$	output: BF16 [1, 32768, 32, 128]，只读取选中位置

例如，合同中的 expand 节点把 score_topk 产生的块索引接到自己的 Schedule，再写出供 attention 消费的 token 索引。下面保留原 JSON 的数据流字段，省略身份校验字段：

```
{
  "id": "expand",
  "schedule": "corpus/schedules/qa-expand-t32768.json",
  "inputs": ["block_indices"],
  "outputs": ["token_indices"],
  "views": {"block_indices": "identity", "token_indices": "identity"},
  "depends_on": ["score_topk"]
}
```

编译器逐阶段检查 Schedule，也检查 Program 的公共输入输出、中间张量形状与 dtype、生产者和依赖关系；例如 `block_indices` 必须先由 `score_topk` 产生，`expand` 才能读取。合同还声明了输入的 singleton 轴视图，使阶段局部 Buffer 与公开张量对应。五个阶段分别生成目标源码，评测核对最终 output，计时覆盖完整调用序列。此处的 v4 是固定源码中的编译验证实例；第7节的 127.8 ms 历史 QSA 结果绑定它自己的旧版程序与设备收据。

4.6 精确目标文档

同一份执行计划语言要面对不同硬件，具体能力由目标文档（Target）说明。当前八个目标分属 NVIDIA、Apple、AMD、Hygon 和 MetaX；每份文档分别声明线程组宽度、存储空间、可用指令、代码对象与资源限制。编译器按目标的精确 ID 准入，缺少的硬件事实报告为“未建模”。Triton、Metal、原生 CUDA 与 CuTe DSL 则是生成源码的路线；其中 Triton 服务多个厂商，不以厂商名划分公共 IR[4, 2]。

4.7 表示变更的验收义务

新原语会改变作者能写什么，也会改变编译器必须检查什么。因此，一项 IR 扩展要同时说明结果类型、读写效果、合法性规则、分析所需信息和目标上的实际行为，再用正反用例检查这些关系。对于能够由现有原语组合的算子，先建立任务合同和参考实现；遇到确实无法执行的执行行为，再扩展语言与后端[1, 3]。

5 编译器：从局部化检查到目标源码

5.1 分层拒绝与反馈

编译器先把作者的程序构造成带类型的 IR，再检查程序中的关系是否成立。例如 FMA 需要三个输入；若候选漏掉第三个读取，检查结果会在 `operations[3].reads` 指出 `ELEMENTWISE_ARITY`。作者据此补上缺失的数据边，而不必先编译、运行 GPU 再从错误输出猜原因。其余检查归入四类：

`schedule_semantics` 调度语义

`hardware_conformance` 硬件符合性

`data_consistency` 数据一致性

`program_safety` 程序安全

一条诊断（Finding）带有稳定代码、位置、类别及阻断范围，Python 前端还能把位置指回源文件。建议性提示另存，不改变候选的检查结论。通用规则通过后，后端还会检查这条生成路线能否支持候选所用的操作与硬件特性。通过这些门，意味着候选可以进入下一步编译；设备上的答案与速度仍要分别测量[2, 5]。

5.2 源码生成与下游工具链

检查通过后，后端生成一份可阅读的目标源码。选择 Triton 时，这份源码还要交给对应厂商的 Triton 工具链；Metal、原生 CUDA 和 CuTe DSL 各有自己的生成与编译入口。目标文档声明最终代码对象的类别，执行器按该类别加载产物。这样，从执行计划到 GPU 结果的过程可以逐段追踪：源码是否生成、工具链是否编译、设备是否可加载、输出是否算对、计时是否可信，各有自己的记录 [2]。

5.3 Target 与生成路线如何保持分离

同一代码生成机制可以服务不同厂商：当前 Triton 路线就接入了 NVIDIA、AMD、Hygon 和 MetaX。厂商身份由精确目标文档声明，后端只说明自己能生成哪类代码对象。表4列出这些关系。新增目标时，先核对它声明的指令、资源和代码对象，再验证所选后端与工具链；添加一个目标名并不会自动带来设备执行资格。

表4 固定源码中的目标与生成路线。代码对象来自各自 Target 文档；设备证据另见第7节。

Vendor	精确目标 ID	代码对象	当前主要源码路线
NVIDIA	sm_100a, sm_103a	CUBIN	Triton; 原生 CUDA; CuTe DSL
Apple	apple_gpu_family7, apple_gpu_family8, apple_gpu_family9	Metal archive	Metal
AMD	gfx1151	HSACO	Triton / ROCm
Hygon	gfx938	HSACO	Triton / DTK-HCU
MetaX	xcore1002	MCFATBIN	Triton / MACA

目标文档还拥有线程束或波前宽度、资源上限和指令事实。某项上限尚未声明时，分析会把它列为未建模，而不是借用另一型号の数値。MetaX 提供的 `triton_arch=80` 只是适配工具链 API 所需的值；物理目标仍是 `xcore1002`。这种区分使报告和代码生成都能说清实际使用了哪台设备 [4, 2]。

5.4 从 Finding 到物理资源观察

计划通过静态检查以后，作者还需要了解它在机器上付出了什么代价。Schedule 中声明的逻辑寄存器 `tile`，并不是每线程实际分到的物理寄存器；后端还可能增加暂存、栈与共享内存。工具链编译后的资源报告可在不运行 GPU 的情况下收集。若候选正确但偏慢，目标设备上的性能剖析进一步帮助作者提出关于访存、占用率或工作分配的假设。

这三种反馈各回答一个问题：计划关系是否成立，编译产物用了多少资源，设备执行时发生了什么。它们绑定同一候选的源码和产物身份，方便作者沿着观察逐步修改。分析缺少目标校准时，报告保留未知状态。细节见 [编译资源分析与校准边界](#)。



图 4 作者沿着计划、编译产物和设备运行三个层次读取反馈。图按 [仓库既有说明图](#) 改绘；每一层都为下一次修改提供不同的观察。

以下命令可在项目根目录离线检查 FMA 示例，并生成 Triton 源码。它让读者先观察 Assessment 与生成结果；工具链编译、GPU 判对和计时属于后续步骤：

```
PYTHONPATH=src python3 -m open_cake_ir.cli compiler assess \
  examples/python/fma.py --format text
PYTHONPATH=src python3 -m open_cake_ir.cli compiler lower \
  examples/python/fma.py --output /tmp/cake-fma.py --format text
```

5.5 Corpus Gate 的含义

当前固定源码 677eb444 的语料门有 179/179 项符合预期。它逐项对照已审查的接受或拒绝结果，帮助维护者发现编译器语义变化带来的回归。覆盖报告同时指出两个已声明但尚无该门检查的目标：Apple family7 和 family9。通过数因此只描述这组软件用例；设备运行与性能由各目标自己的实验继续验证 [7, 5]。

6 实验方法与证据等级

6.1 一次 Run 的四阶段

一次运行从固定任务开始，沿四个阶段推进：

1. 作者提出结构不同的执行计划或完整程序，记录每次改了什么；
2. 编译器先检查类型、合法性和后端支持，再用有目标校准的成本估计安排设备评测顺序；
3. 对可运行候选核对完整输出；正确后按目标设备的协议计时，并在需要时采集剖析数据；
4. 根据具体诊断继续修改候选，或将反复出现的编译器缺口留给后继版本处理。

成本估计节省搜索时的设备时间，最终接受仍取决于外部答案和实机测量。每种目标硬件分别声明计时器、测量区间与样本前的设备状态；缺少这些条件时，报告保留计时覆盖缺口。

6.2 双时间尺度与 Finding 的负责位置

图5展示了两种改动的节奏。一次运行只改变候选程序，任务、编译器、目标和测量规则保持原样。运行留下的错误、正确性收据与性能样本，为下一轮候选提供依据。运行结束后，维护者再查看反例：问题是候选写法、检查规则、生成路线，还是缺少一种表达？需要修改编译器时，改动先成为新提交，通过语料门和审查，再进入下一次运行。有些性能差距只适合继续探索候选，记录“暂不提炼通用变换”也是结论。

一份 C550 M17 的实际运行展示了这条路径。在固定源码 896e0887 下，作者进行了十个回合，九份候选被拒绝。第二轮的 ACCESS_TILE_MISMATCH 直接指向不一致的访问映射；第六轮



图 5 候选在固定编译器的一次运行中迭代。下方的虚线表示运行结束后，已归档的问题可能推动编译器改动；新版本通过审查后才用于下一轮。

产生的候选后来通过五类输入的独立正确性检查和 MCPTI 成对计时。固定基线与候选的中位数分别为 12.032 和 11.008 μs 。这份记录覆盖了反馈、筛选、确认到终态的过程；计时只对应那次 `local_serialized` 容器环境。详情见[架构案例](#)。

6.3 研究对照的单位和参考访问

研究比较以一次独立运行为单位，而不是把同一运行中的多个候选当作重复样本。干净起点允许作者看任务规格、外部答案和高层代码，目标的完整低层实现则留在作者视野之外；研究已知内核的复现时，参考实现可以成为允许的材料。比较 Cake 和直接 CUDA 编写环境，还须固定模型、任务、预算与评测规则。搜索读数用于挑选候选，结论取自候选固定后的独立确认。基础设施中断在报告中记为缺失，保留它已经消耗的成本 [6, 15]。

6.4 证据保存、回放与结论资格

每份候选、评测收据和终态都按事件顺序追加保存。审计者可以离线重算候选选择与停止状态，并检查报告是否来自这些原始材料。还要分别核对归档内容能否完整回放，以及当时的写入与发布过程是否满足文件监管要求。前者说明记录可读，后者决定它能否用于晋升或研究估计。协议将两项分别记为 `archive_integrity` 与 `filesystem_custody_verified`。历史运行始终按当时的源码与协议审计 [5]。

6.5 结论阶梯

一份结果能支持多强的说法，取决于它实际通过了哪些步骤。表 5 列出从计划检查到研究比较所需的证据，也供后面的平台案例对照。

源码版本由干净的 Git 提交确定：编译器身份写作 `open-cake-ir@<commit>`，执行器还要加上精确目标。本文固定的提交用于说明当前软件；后面的历史测量仍保留各自运行时的提交、样本与监管记录。

7 实现覆盖与代表性设备案例

7.1 平台覆盖是分层事实

仓库已接入五家厂商，但“能生成代码”“设备算对”和“计时可比较”是不同阶段。表 6 先给出每条路线已经到达的范围；具体数值在各自的任务、设备和基线之内解释。各平台的原始报告与收据仍是结果来源 [2]。

表 5 从计划检查到研究比较，各种结论需要的证据。

可陈述的结果	必要证据	尚需另行验收
结构与目标准入	typed IR、精确 Target、Finding 与后端预检	工具链编译和加载
设备正确性	完整输出对外部 oracle，覆盖规定形状与分布	计时质量和性能收益
局部性能	固定候选与基线、共同计时区间、质量通过	跨任务或跨硬件泛化
Program 或服务收益	完整调用路径、dispatch 与应用层验收	Agent 处理的因果效果
研究归因	预注册处理、独立 Run、共同确认与缺失规则	未测试任务与平台的外推

表 6 截至报告快照的代表性平台能力与主要解释边界。

平台	已报告的执行范围	需保留的边界
NVIDIA	B300 的单 Kernel、部分完整 Program；B200 另有固定案例	FlashInfer 外部比较有通过与未通过质量门的边，按任务解读
Apple	Metal 固定算子与 TaskLab 优化记录	已验收设备和计时口径不推广到全部 family 或完整 Program
AMD	gfx1151 设备调查与 smoke	计时器绝对时间未对齐，尚无合格的完整 Agent 收益结论
Hygon	BW1101 / gfx938 固定任务与 HIP 路线	短 Kernel 的计时分辨能力限制部分比较
MetaX	C550 固定单 Kernel 及若干完整输出；单 Kernel 配对计时和 profiler	完整 Program 普通 Run 计时与完整 provider 闭环仍需验收

7.2 NVIDIA：任务族覆盖与外部比较

在 B300 上，FlashInfer 逐任务综述 为每个固定形状保留原起点、改写产物和外部实现。截至 2026-09-21，26 个任务中有 16 个完成三方数值比较。按综述选定的代表产物，对外部实现的计时结果分为：2 项合格领先、6 项未检出达到预设门槛的差异、4 项合格落后、4 项缺少合格的外部计时；其余 10 项还在完成外部性能比较。这个分布展示任务进度，不能合成为一个平台加速比。

逐任务记录更能说明优化发生了什么。任务 022 的四组候选对外部实现取得合格领先，但它与原起点之间的计时质量不足，原起点仍保留为比较对象。任务 003 的整行改写相对中间候选改善，面对外部实现仍落后。这些结果把“相对自己的上一版进步”和“达到外部实现水平”分成两件事。独立 NCU 剖析可帮助解释工作分配与资源使用；计时判断仍依据原来的 CUPTI 样本及质量门 [8]。

B300 的服务实验、CTA 宽度验证、FlashInfer 改写和 CAKE 任务复现使用不同基线与协议，分别放在报告中。B200 的 FMA、状态操作和 QSA 案例也沿用各自的历史提交。

7.3 Apple、Hygon、AMD：不同结论等级

Apple 的 Metal 记录涵盖几台不同设备。M4 上两个固定的 FP32 行归约任务，相对各自的起点保留了 1.107 和 1.138 倍的历史改进；M1 Pro 上的小形状 GEMM+SiLU，相对朴素任务基线确认了 23.604 倍。后一数值主要说明起点留下了很大优化空间，所用基线与专家库实现不同。M2 的 GEMM 搜索虽有较低读数，计时稳定性尚不足以给出性能结论。Metal 的样本覆盖整个 command buffer，并按重复调用均摊；它和 NVIDIA 的 CUPTI 样本各有自己的区间 [9]。

Hygon BW1101 展示了另一种结果组合。逐通道矩任务从 9.439 降到 6.719 μs ，原记录判为确认加速；prelu 则从 5.439 增至 9.759 μs ，属于确认变慢。多项短内核的两边都读到 5.439 μs ，来源把它们标为测量分辨能力待查，而非真正持平。部分历史行没有在汇总表转录完整形状，读者可以沿链接回到原运行查看 [10]。AMD gfx1151 现有 Triton/HSACO 路线和设备调查；两种计时器的绝对时间仍需对齐，因此其结果页暂不列加速比 [11]。

表 7 Apple、Hygon 与 AMD 的代表性观察。每行沿用自己的任务基线和计时资格。

目标	固定案例	观察	可陈述的范围
Apple M4	两项 FP32 行归约	1.107 / 1.138 倍	各自任务的历史晋升记录
Apple M1 Pro	GEMM+SiLU，小形状	23.604 倍	相对朴素任务基线，非专家库对照
Hygon BW1101	逐通道矩	1.405 倍	首个保留合格 Run 的本机结果
Hygon BW1101	prelu	0.557 倍	确认变慢，应保留负结果
AMD gfx1151	RMSNorm smoke	延迟缺失	路线调查；计时器未对齐

7.4 MetaX：单内核、完整输出和实际 Run 分别验收

C550 的记录覆盖三件互有关联的工作。第一项是固定形状 M17 GEMM 的单内核分块优化，下节详述它相对本机基线的独立确认。第二项是 GQA、MLA 和 MoE 等 17 个程序变体的完整输出核对，86 个 case 全部通过；这些收据记录的是正确性，没有普通程序计时样本。第三项是一次十轮 Agent Run，保留了候选被拒、修正和最终确认的过程。该次 Run 中 12.032/11.008 μs 的配对中位数属于固定基线与 local_serialized 运行环境。三种观察各自回答实现、判对和作者流程的问题，详见 C550 专题与集成案例。

7.5 案例 A : C550 的局部 tiling 收益

1.241 倍 C550 · FP16 GEMM · $M = 17, N = 128, K = 2048$

基线 $72.448 \mu\text{s}$ → 候选 $58.368 \mu\text{s}$; M tile $64 \rightarrow 32$ 。独立确认的正确性与测量质量门通过。

这是 `local_serialized` 范围内的本机 authoring 对照，支持这个形状上的局部调度改进。这次只改变 M tile，独立确认说明更小的 tile 对当前形状有利。将这一观察提炼为跨目标经验，还需要在目标设备上重新选择参数并验收收益 [12]。

7.6 案例 B : B300 的对齐条件与质量门

1.081 倍 B300 · FlashInfer 任务 026 · 守卫式对齐

固定 `generic sliced-w8` 对照 $6.4005 \mu\text{s}$ → 候选 $5.920 \mu\text{s}$; 同次候选对照边通过计时质量门。

这项对齐改动对固定的通用实现取得了可确认的局部收益；与外部参考的那组样本没有通过 CV 质量门，因此外部胜负仍未确定。任务 008 则把两阶段 Program 跑通并通过 2550 份数值快照，但候选对内部对照和外部参考的计时都不稳定。它提供了完整程序的正确性记录，性能判断需要新的合格样本 [8]。

7.7 两个局部案例的结论范围

两个案例分别说明了分块与对齐可以在固定任务上改进本机候选。它们使用不同硬件、任务和计时协议，因此正文按案例报告，同时保留变慢、差异不足和计时失败的记录。当前 [状态页](#) 也没有汇总全项目已验收的 Study Report；各项结果继续从自己的报告和收据追溯。

7.8 历史 B200 案例的放置方式

2026 年 9 月旧版报告还保存了两项 B200 案例。QSA 的 $T = 32768$ 完整程序，历史确认候选和同次 CUDA 黑盒参考分别约为 127.8 与 676.4 ms，展示了多阶段计划与程序级评测的一次实际使用。Flash-KMeans 的固定形状配对搜索，每组有三次独立运行；Open-Cake 与直接 CUDA 编写环境的确认终点中位数分别约为 1.512 和 5.342 ms。这项本地实验采用 150k token 和 max 努力级别；CAKE 论文采用另一套 80M-token 协议，第 8 节将并列说明条件。两项结果都作为历史快照引用，完整任务、软件和样本来源列在附录 [6]。

8 与 CAKE 对照：相同的问题，不同的证据

本仓库与 CAKE 有共同的研究问题，也有可以直接检查的重叠任务。不过，论文聚合数字、公开的 CAKE 生成产物、本仓库运行记录和某个任务的外部参考，各由不同材料产生。表 8 先比较研究设计与实现范围；下节再看同一 TinyGEMM2 任务上能够进行的数值和速度对照 [1, 6]。

CAKE 论文表 2 以 B200 上固定的 FlashML 基线 (0.938 ms) 为参照，在 80M token 截点报告 Cake IR 三次运行最优候选的中位数为基线的 1.144 倍，直接 CUDA/PTX 为 0.928 倍。这里转录的是论文结果。本仓库历史 Flash-KMeans 实验使用 150k token、不同努力级别和自己的基线，因此表 8 并列的是协议，而不是用两个实验的加速比互相比大小 [1, 6]。

表 8 CAKE 论文与本仓库在研究问题、目标和已获得证据上的对应关系。论文数字与本地运行分别标明来源。

问题	CAKE 论文 v1	本仓库当前可读证据
执行计划	硬件显式 Cake IR; NVIDIA Ampere-Blackwell	独立 typed Schedule/Program; 五 Vendor、八精确 Target 文档
静态反馈	Verifier 四类门与目标校准成本排序	共享四类诊断和后端预检; 无目标校准时报告覆盖限制
作者处理	B200、固定模型和 scaffold, Cake 对直接 CUDA/PTX, 3+3 次, 80M token	历史 B200 配对运行有自己的 150k/max 条件; 当前无可与论文对齐的 clean-start 估计
专家端点	KDA、TinyGEMM、Alpha-MoE 等生产任务及服务/portfolio 结果	部分固定任务复现与完整输出; 大范围 dispatcher、服务及部分原语仍缺
非 NVIDIA	原论文未测目标侧 lowering 与成本	Apple、AMD、Hygon、MetaX 逐目标实现; 正确性和计时资格不均

8.1 TinyGEMM2 : 相同任务上的性能差距

TinyGEMM2 提供了更具体的对照。仓库固定三个 B300 BF16+bias 形状, 用独立 FP64 数学参考核对结果, 再要求候选与官方导出产物逐位一致。本地候选的 30 次检查和官方导出的 15 次检查全部通过。随后, 五轮交替顺序的 CUPTI 冷 L2 测量保留了两组完整样本。表9列出 stage4 实现的中位数: 本地候选已经重现了任务的数值结果, 速度仍落后于对应的 CAKE 导出产物 [13]。

表 9 B300 三个固定 TinyGEMM2 形状的历史中位数 (μ s)。减速倍数使用原始成对样本计算; 此表比较生成产物, 不是论文的智能体起点实验。

$B/N/K$	CAKE 导出 stage4	本地 stage4	本地相对减速
1/128/720	2.720	100.192	36.77 倍
16/1024/1024	3.040	105.825	34.81 倍
64/4096/3072	21.216	289.186	13.63 倍

本地 stage4 相对 CAKE 导出 stage4 的描述性减速



图 6 严格数值检查通过后, 本地 stage4 在三个 B300 固定形状上仍比官方 CAKE 导出 stage4 慢。图示历史配对中位数; 各轮原始样本与质量记录见 [专题](#)。

2026 年 9 月 24 日 B300-M4 后继诊断。 表10在同一轮三臂比较中重新测量旧 Triton、后继 Compiler 产物和官方 CAKE 导出产物。后继编译器源码为 4da760be; 前两形状使用 Schedule 声明的原生 CUDA warp MMA 路线, $K = 3072$ 使用按 K 片段直接加载的 Triton 路线。三个形状各有五种输入

分布，后继输出均与导出产物逐位一致，独立数学参考检查通过，输入保持不变。五轮交替顺序测量中，每臂每轮保留 25 个 CUPTI 冷 L2 样本，且每臂只启动一个内核；表中的倍数取五轮配对延迟比的中位数，不能用已四舍五入的表格延迟相除替代。

表 10 B300-M4 后继诊断，三个固定 TinyGEMM2 形状的延迟中位数 (μs)。旧到新的提升、后继相对 CAKE 的延迟比均按同轮配对数据计算；这不是正式 Evaluation，也不是 CAKE 论文的智能体起点实验。

$B/N/K$	旧 Triton	后继	CAKE 导出	旧/后继	后继/CAKE
1/128/720	100.256	2.784	2.624	36.045 倍	1.061 倍*
16/1024/1024	106.048	3.424	3.008	30.972 倍	1.138 倍
64/4096/3072	289.123	24.672	21.408	11.722 倍	1.151 倍

* B1 的 CAKE 臂最大轮内变异系数为 8.137%，超过预定的 5% 门限；该臂的外部延迟差仅作描述。其余旧/后继配对边均通过此门限，B16/B64 的后继/CAKE 配对边也通过。

已观察到的机制与界限。旧 Triton lowering 将整个 16×1024 操作数装入后再对四个 $K = 256$ 片段执行 `tl.gather`；按片段直接加载显著缩小了离线生成代码，并在三个形状上消除了多数延迟。对两种短 K 形状，后继 Schedule 进一步明确四个有序的 FP32 部分积、 $K = 64$ 的 TMA descriptor 片段、生产者与计算组的同步及 warp 局部 `mma.sync`，保持原有求和与 BF16 写回语义。一个以标量 global-to-shared 拷贝代替 TMA 的有界原型虽然逐位正确，在 B1/B16 上分别达到 19.840/23.360 μs ；改用四个 K64 TMA box 后的短 K 路线显著更快。把 $K = 256$ 一次放入单个 descriptor 的尝试则在 `cuTensorMapEncodeTiled` 阶段被拒绝，不能当作可运行的优化。对长 K 形状，保持两个执行组、两级流水；把深度降为一级虽仍逐位正确，在独立配对测量中反而慢 1.538 倍。上述对照支持所选发射方式和分工对这三个形状的改进；缺少可用的动态 profiler 计数器，尚不能把全部收益唯一归因于某一硬件资源。

继续追赶 CAKE 的固定形状复测。表 11 保留了前表之后的两个提交，不能把不同行的延迟相除当作同轮比较。 $B = 64$ 的后继按固定形状将输出特征 tile 从 16 增至 32，保持四路 $K = 256$ 部分积、两个执行组和两级流水；五种输入均逐位一致。独立复验后，提交 21abdd5d 的产物在五轮配对冷 L2 CUPTI 测量中以 19.904 μs 对 21.440 μs 稳定快于 CAKE 导出产物。该选择只用于已测的 64/4096/3072 形状，不推广为通用 tile 规则。

两种短 K 形状的原生 emitter 原先把 Schedule 中排在 MMA 前的 bias load 发射到归约之后，使全局读取落在计算关键路径。将其提前并预取 TMA descriptor 后，提交 35f66aca 的十个形状与输入分布组合仍全部逐位一致； $B = 16$ 缩到 3.040 μs ，距 CAKE 的 3.008 μs 约 1%。 $B = 1$ 本地中位数 2.592 μs 低于 CAKE 的 2.624 μs ，但两臂最大轮内变异系数分别为 5.557% 和 8.080%，都超过 5% 门限，不构成合格超越。减少 TMA 生产者 warp、改用 timed wait 和一级流水均无稳定收益；交换特征与 batch 的 CTA 方向虽有小幅改善，当前 Schedule 尚不能显式表达对应的寄存器结果与公开输出的转置关系，因此没有将原型偷渡到后端。

表 11 B300-M4 最新固定形状诊断中位数 (μs)。每行各自完成五轮交替顺序、每臂每轮 25 个 CUPTI 冷 L2 样本；倍数为同轮 CAKE/本地延迟比的中位数。各行是不同作业，不是一次三形状联合 Evaluation。

$B/N/K$	本地源码	本地	CAKE 导出	CAKE/本地	外部质量
1/128/720	35f66aca	2.592	2.624	1.012 倍	CV 未过
16/1024/1024	35f66aca	3.040	3.008	0.979 倍	通过
64/4096/3072	21abdd5d	19.904	21.440	1.079 倍	通过

该方向与提前 bias、descriptor 预取合并的 $B = 1$ 原型曾测到 2.528 对 2.592 μs ，但本地与 CAKE 两臂最大轮内变异系数分别为 7.925% 和 9.026%，同样不能据此宣称超越。

前一轮原始记录位于 B300-M4 的 `gpuq-cd8190e80e06` 作业；Finding F-2026-09-24-002 的第 10-13 项索引前一轮与一级流水消融，第 17、22、24 项索引最新的 B64、B16 和 B1 产物及原始报告。截至本次更新，后继代码和 Finding 仍在任务分支，尚未进入维护分支。这次是 broker 准入的定制诊断：B300-M4 的 broker 未提供现有正式 Executor 所要求的 GPUQ_JOB_ID，因此尚无正式 Evaluation 收据，不进入 `docs/results/nvidia/` 的发布成绩。CAKE 导出产物原有的更大形状集合与服务验证，以及 KDA、Alpha-MoE 的完整任务，仍在后续复现范围之外。

9 跨硬件复用：从一次改写到可检验的收益

9.1 可复用的是机制，参数要在目标卡重选

一次优化既可能发现可复用的做法，也会得到只适合当前设备的参数。比如，融合私有的中间张量可以省去一次写回和重读；能否融合取决于消费者、生命周期与舍入语义。具体的 tile、执行组和流水线深度，则要在目标卡上重新选择。可确定性表达的改写可以成为带前提和拒绝原因的显式 pass；只有一次有效的局部参数选择，仍作为任务经验保留 [14]。

9.2 E/P 四组实验

若要知道经验究竟提供了多少帮助，先要把“让智能体读说明”和“让智能体调用现成改写”分开。图7以 E 控制额外机制材料，以 P 控制显式 pass 的调用权，形成四种条件。四组共享任务、编译器、目标设备、正确性和计时规则；工具权限由运行环境实际隔离。 $P1$ 组仍需知道调用的最小接口，所以 E 测量的是接口之外的说明和案例。目前软件协议已接入，四组在共同目标与预算下的实机迁移实验尚未进行 [15]。



图7 四组迁移实验的处理条件。 E 是额外说明与案例， P 是显式变换调用权；所有组使用相同的编译器和设备评测。此图表示实验分组，尚无实机处理效果。

令 p_{ep} 为在预注册预算内经新鲜确认、达到本机预定改善阈值的 Run 比例。预定主要对比为

$$\begin{aligned}\Delta_E &= \frac{1}{2}[(p_{10} - p_{00}) + (p_{11} - p_{01})], \\ \Delta_P &= \frac{1}{2}[(p_{01} - p_{00}) + (p_{11} - p_{10})], \\ \Delta_{EP} &= p_{11} - p_{10} - p_{01} + p_{00}.\end{aligned}$$

一次独立运行是重复单位。正式研究按任务等权汇总，保留各任务内四组的配对关系；搜索成本、预算耗尽和基础设施缺失也按事先约定记录。四组全部运行并经共同确认后，才能计算上面三个处理效果。

9.3 从 B300 到 Hygon：可执行与性能的分界

迁移专题记录了一次具体尝试。B300 上的 `pairwise_sqdist` 候选把 K 维按 256 分块；在固定 FP32 形状上，五类输入检查和 CUPTI 配对计时通过，相对本机基线从 411.7945 降到 53.856 μ s。将同一数学任务准备给 Hygon BW1101 时，团队保留张量、输入、参考答案和容差，先把旧版 Schedule 的角色表示显式适配到当前 `execution_groups`。适配后的候选及同卡起点均通过编译器检查，并由 Hygon Triton 编成 HSACO。

原 `bw1100` 节点的八卡被其他 GLM 进程占用，实验止于离线准入。另一台 `bw1100-1` 具有空闲 BW1101，但宿主内核和环境与前者不同；因此先为该节点单独捕获 Executor，再在干净源码 `4c9f4cc0` 上运行相同合同。五类输入在计时前后均判对；新鲜 HIP 配对确认质量通过，同卡起点/来源 K=256 候选为 517.9645/748.749 μ s，十对均是起点更快。故该机制能够正确执行，原参数却在此节点产生负迁移。本地串行锁不能排除没有使用同一锁的外部任务；不同 CUPTI/HIP 计时器的绝对时延也不构成跨卡速度比。

在运行下一次设备实验前，冻结两个只改 K tile 的 Hygon 后继：128 和 64。离线编译均报告零 scratch，分别占 252 和 148 个 VGPR；按预定的资源排序只选择 K=64 上卡。它相对 K=256 的生成源码仅改变分块值与调度身份。在相同五类输入、whole-K 起点及 HIP 配对协议下，新鲜独立确认全部判对并通过计时质量门，起点/候选为 518.524/189.586 μ s (2.735 倍)，十对均是候选更快；K=128 没有设备计时。因此，K 维分块这一来源机制可以在目标卡重新选参后奏效，但来源参数不可照搬。另在上卡前冻结一个未见的同算子形状 `R=1024,K=512,N=64`，只比较已选 K=64 与该形状的 canonical whole-K 起点，不再试其他 tile。五类输入在首次及新鲜独立确认中均零不匹配、计时质量通过；确认中位数为 106.232/97.593 μ s (1.0885 倍)，十对均为候选更快。第二个形状提供有限的 Hygon 本机形状泛化证据，但收益远小于 K=1024 的 2.735 倍；B300 没有在新形状上的来源性能收据，也没有跨算子结论。这是一例限定形状的人工机制迁移和 Hygon 本机收益，并非控制作者与预算、随机分配材料 E 或变换权限 P 后得到的 Agent 处理效果。

难点也并非单一后端开关：同一带循环归约的 Schedule 在当前 Metal 路线无法表达；Triton 能向 AMD、Hygon 生成代码，却不保证源参数的资源分配或速度；同 ISA 的第二台 Hygon 宿主仍需独立 Executor；C550 的容器锁边界和 M2 的计时质量分别限制设备主张。可表达性、目标选参、宿主身份、测量与因果归因须分层验收。

10 限制、可复查性与结论

Open-Cake-IR 已经把候选生成、静态检查、目标代码生成和设备反馈接成一条可追踪的路径。在当前源码上，179 项语料符合预期；在若干固定 Workload 上，也已有设备正确性与局部性能结果。这些结果回答了“系统能否表达、检查并运行具体候选”。要回答“这一机制能否稳定带来跨任务、跨平台收益”，还需要更完整的目标侧测量和预注册对照实验。

10.1 解释结果时的四项限制

与 CAKE 的关系。本文复现的是论文描述的设计问题与实验思路，并独立实现 Compiler。论文公布了系统机制和汇总结果，但缺少把原始编译器、完整 IR 与 Verifier、agent scaffold、clean-start 轨迹及计时细节一起重建的材料。因此，同名任务的对照应从输入合同、参考实现和测量范围逐项核对[6]。

平台覆盖。五家厂商、八份 Target 文档界定了可声明的目标；每个平台还须单独取得工具链、数值、计时器和 profiler 的运行收据。179 项 Corpus Gate 尚未检查 `apple_gpu_family7`

与 `apple_gpu_family9`。MetaX 的完整输出验证和 AMD 的计时器调查，也分别处于不同的证据阶段 [7, 2]。

性能范围。一个形状的候选优于本机基线，并不意味着它胜过外部专家实现，或能直接用于多形状应用。后者还涉及分派守卫、尾部输入、回退路径和框架开销。历史 QSA 数字覆盖完整 Program 的 GPU 区间；M17 数字覆盖单内核。两者都不能直接换算成模型或服务延迟。

机制归因。工程 Run 和局部消融可以发现问题、改进系统。若要判断作者环境或迁移材料带来了多少增益，还须固定处理条件，进行独立 Run 和共同确认，并说明缺失结果如何计入分析。 E/P 四组的实机对照尚待开展。

10.2 下一步的可检验目标

接下来的实验先补齐各目标的完整输出验证、计时区间、设备状态重置和测量分辨能力，再把单内核结果接入多阶段 Program 与目标框架。对反复出现的表达或分析缺口，记录 Finding 和反例，在后继提交中补上 Verifier 规则、IR 能力或带前提的编译器变换，并观察它能否解决后续任务。迁移实验则固定来源机制、目标开发集和 E/P 四组材料与权限，按各目标自己的本机基线报告确认率、搜索成本和条件性能。这样，代码能力的增长与经验迁移的收益便可以分别检验。

A 术语、源码入口与完整示例

表 12 文中的术语按负责事实区分。英文名是 API 查找键，表中中文名用于叙事。

对象	本报告中的固定含义
Workload	外部算子语义、输入域、oracle 与数值容差
Schedule	单内核的操作、资源、执行组、访问与同步承诺
Program	公共张量、多个叶子 Schedule 的阶段顺序和绑定
Target	精确设备声明；事实未建模时不借相邻型号
Run	一次冻结的作者环境、候选、预算与终态
作者	在一次 Run 中提交候选的人或智能体；可见材料与工具由运行规格限定
Study	运行前固定研究处理、分配、估计量和分析规则
Finding	可定位、可归属的结构、目标或后端诊断

当前 [Softmax 文件](#) 是第 4 节运行示例的完整可读源码：

```
from open_cake_ir.compiler import frontend as cake

@cake.schedule(name="softmax-b8-smoke", target="sm_100a", backend="triton",
               entry_point="cake_softmax_b8_smoke",
               residency={"ctas_per_multiprocessor": 4,
                          "registers_per_thread": 96})
def softmax(lm, x: cake.Tensor((8, 512, 128), "fp32"),
            y: cake.Tensor((8, 512, 128), "fp32", mode="output")):
    compute = lm.role(execution_groups=[0, 1, 2, 3])
    row_block = lm.program(x, axis=0, dimension=1, tile=64)
    batch = lm.program(x, axis=1, dimension=0, tile=1)
    with compute:
        x_tile = lm.load(x[batch, row_block, :], reuse="reused", id="load_x")
        rowmax = lm.reduce(x_tile, op="max", axis=1, scope="cta", id="row_max")
        shifted = lm.sub(x_tile, lm.broadcast(rowmax, axis=0), id="shift")
        weights = lm.exp(shifted, id="exponentiate")
        rowsum = lm.reduce(weights, op="sum", axis=1, scope="cta", id="row_sum")
        y_tile = lm.div(weights, lm.broadcast(rowsum, axis=0), id="normalize")
        lm.store(y[batch, row_block, :], y_tile, id="store_y")
```

这里的 Python 接口通过 AST 构造与 JSON 相同的规范计划；`Compiler.load()` 默认读取项目的当前配置。要在具体 GPU 上运行，还需匹配目标工具链，并完成正确性与性能验收。[Python 前端文档](#)列出了支持的语法及源码位置诊断。

B 结果来源与历史身份

表 13 正文各类结果的第一阅读入口。报告页面是带范围的投影，原始运行收据继续拥有测量与监管事实。

范围	固定来源或索引
当前 Compiler	状态页、版本清单与精确目标文档
B300 FlashInfer	逐任务状态；每行链接自己的 Finding 与收据
B300 TinyGEMM2	历史严格数值与成对计时报告；后继 B300-M4 诊断索引 F-2026-09-24-002（尚未正式发布）
Apple、Hygon、AMD	各平台 发布汇总 与原记录
MetaX C550	平台专题及 当前 Run 案例
迁移离线试点	机制与证据边界
历史案例	QSA 与 Flash-KMeans：2026-W36.1 旧报告及其证据附录；退役路径按 history 标签回放

历史 Flash-KMeans 的六次终点属于固定 $B = 32, N = 65536, K = 1024, D = 128$ 、BF16 输入的 B200 Workload，三对延迟（Open-Cake/CUDA，ms）为 1.191845/3.898164、1.511927/7.130795 和 1.512163/5.342292；两组各取自己的中位数，范围不是置信区间。历史 QSA 的 $T = 32768$ 完整 Program 候选和同次参考分别为 127.821446/676.423598 ms；该时间不含 Python 包装开销。这里只转录旧报告的有界结论与身份，不以新版 Compiler 重释旧原始记录。

C 复现边界与报告构建

本文的数字来自已存在的报告、Finding 与原始收据定位；写作和 TeX 编译没有启动新的 provider、GPU Campaign 或计时。阅读者可从固定源码检出运行离线入口，看到 IR 构造、Assessment 与 lowering；设备结果则须在原任务的目标、工具链、参考访问和监管环境下重放。报告源文件位于 docs/open-cake-ir-technical-report.tex，在装有 XeLaTeX、中文字体和本仓库已有图像的环境中可直接编译。历史示意图保留其原始来源；其文字表达的能力范围按正文当前源码重新核对，不用旧图中的版本值替代当前状态。

阅读与引用说明

本文是项目维护者撰写的仓库技术报告，无 DOI、期刊或同行评审声明。引用设计时请固定本报告及其所读源码提交；引用性能时还需追溯案例自己的执行源码、精确目标、Workload、baseline、oracle、计时区间与质量门。以下文献中的仓库链接均固定到本文所读的 677eb444，而后继 TinyGEMM2 诊断由正文所列 4da760be 与 B300-M4 原始记录另行定位。正式英文引文题名沿用仓库 CITATION.cff 的 preferred-citation；封面的中文题名概括本文的研究对象。

参考文献

[1] Z. Ye et al. *CAKE: Compiler-Agent Co-Design for Frontier Kernel Evolution*. arXiv:2608.12629v1, 2026.
<https://arxiv.org/html/2608.12629v1>.

[2] H. Qin. 系统架构与平台能力. open-cake-ir@677eb444, 2026.

[3] H. Qin. IR 指南. open-cake-ir@677eb444, 2026.

- [4] H. Qin. [Compiler 清单与 Target 文档示例](#). open-cake-ir@677eb444, 2026.
- [5] H. Qin. [验收门](#). open-cake-ir@677eb444, 2026.
- [6] H. Qin. [论文与本地证据合同](#). open-cake-ir@677eb444, 2026.
- [7] H. Qin. [当前状态](#). open-cake-ir@677eb444, 2026.
- [8] H. Qin. [B300 FlashInfer 任务综述](#). open-cake-ir@677eb444, 2026.
- [9] H. Qin. [Apple 平台结果](#). open-cake-ir@677eb444, 2026.
- [10] H. Qin. [Hygon DCU 平台结果](#). open-cake-ir@677eb444, 2026.
- [11] H. Qin. [AMD 平台结果](#). open-cake-ir@677eb444, 2026.
- [12] H. Qin. [C550 专题与 M17 独立确认](#). open-cake-ir@677eb444, 2026.
- [13] H. Qin. [B300 CAKE 重叠任务对照](#). open-cake-ir@677eb444, 2026.
- [14] H. Qin. [跨硬件优化知识迁移机制](#). open-cake-ir@677eb444, 2026.
- [15] H. Qin. [E/P 消融实验设计](#). open-cake-ir@677eb444, 2026.